


**OPTIMISASI PELATIHAN LATENT DIFFUSION MODEL DENGAN
LOW-RANK ADAPTION UNTUK AUGMENTASI CITRA
PENYAKIT TANAMAN (STUDI KASUS: BAWANG MERAH)**

***OPTIMIZATION OF LATENT DIFFUSION MODEL TRAINING WITH
LOW-RANK ADAPTION FOR PLANT DISEASE IMAGE
AUGMENTATION (CASE STUDY: SHALLOT)***



NIRWANA SAMRIN

D082251003



PROGRAM STUDI MAGISTER TEKNIK INFORMATIKA

FAKULTAS TEKNIK

UNIVERSITAS HASANUDDIN

GOWA

2025

PROPOSAL PENELITIAN

OPTIMISASI PELATIHAN LATENT DIFFUSION MODEL DENGAN LOW-RANK ADAPTION UNTUK AUGMENTASI CITRA PENYAKIT TANAMAN (STUDI KASUS: BAWANG MERAH)

OPTIMIZATION OF LATENT DIFFUSION MODEL TRAINING WITH LOW-RANK ADAPTION FOR PLANT DISEASE IMAGE AUGMENTATION (CASE STUDY: SHALLOT)

**NIRWANA SAMRIN
D082251003**



**PROGRAM STUDI MAGISTER TEKNIK INFORMATIKA
DEPARTEMEN TEKNIK INFORMATIKA
FAKULTAS TEKNIK
UNIVERSITAS HASANUDDIN
GOWA
2025**

LEMBAR PENGESAHAN PENELITIAN**OPTIMISASI PELATIHAN LATENT DIFFUSION MODEL DENGAN
LOW-RANK ADAPTION UNTUK AUGMENTASI CITRA
PENYAKIT TANAMAN (STUDI KASUS: BAWANG MERAH)****NIRWANA SAMRIN****D082251003**

Disetujui untuk diseminarkan

Komisi Pembimbing

Pembimbing

**Prof. Dr. Ir. Zahir Zainuddin, M.Sc.****NIP. 19640427 198910 1 002****Ketua Program Studi S2 Teknik Informatika****Prof. Dr. Ir. Zahir Zainuddin, M.Sc.****NIP. 19640427 198910 1 002**

DAFTAR ISI

LEMBAR PENGESAHAN PENELITIAN	iii
DAFTAR ISI	iv
DAFTAR GAMBAR	v
BAB I PENDAHULUAN.....	1
1.1 Latar Belakang.....	1
1.2 Landasan Teori.....	3
1.2.1 Tanaman Bawang Merah	3
1.2.2 Penyakit Tanaman Bawang Merah.....	4
1.2.3 Diffusion Model	7
1.2.4 Latent Diffusion Model	7
1.2.5 Low-Rank Adaptation	7
1.2.6 Augumentasi Data.....	8
1.2.7 Metrik Evaluasi.....	8
1.3 Rumusan Masalah	9
1.4 Batasan Masalah	9
1.5 Tujuan Penelitian	10
1.6 Manfaat Penelitian	10
BAB II METODE PENELITIAN.....	12
2.1 Jenis Penelitian.....	12
2.2 Tahapan Penelitian.....	12
2.3 Sumber Data.....	14
2.4 Perancangan Sistem.....	14
DAFTAR PUSTAKA	19
LAMPIRAN	22
Lampiran 1a. State Of The Art Penelitian.....	23
Lampiran 1b. Kerangka Pemikiran.....	28

DAFTAR GAMBAR

Gambar 1. 1 Tanaman Bawang Merah	4
Gambar 1. 2 Penyakit Bercak Ungu.....	5
Gambar 1. 3 Penyakit Moler	5
Gambar 1. 4 Penyakit Hawar Daun	6
Gambar 1. 5 Penyakit Bercak Kuning	6
Gambar 1. 6 Arsitektur Latent Diffusion Model.....	7
Gambar 1. 7 Arsitektur LoRA	8
Gambar 2. 1 Tahapan Penelitian.....	12
Gambar 2. 2 Rancangan Sistem. (a) Image Processing (b) Model Klasifikasi.....	14
Gambar 2. 3 Flowchart Proses Pelatihan LDM dengan LoRA	17

BAB I

PENDAHULUAN

1.1 Latar Belakang

Perkembangan arsitektur *neural network* telah memperluas penerapan teknologi kecerdasan buatan (*artificial intelligence*) pada berbagai sektor, termasuk bidang pertanian (Lee et al., 2024). Dalam konteks nasional, sektor pertanian tidak hanya menjadi penopang pembangunan, tetapi juga berfungsi sebagai pilar utama perekonomian (Deng & Qin, 2025), sehingga kemampuan identifikasi penyakit tanaman terutama pada komoditas strategis seperti bawang merah secara cepat dan akurat menjadi aspek krusial dalam mendukung sistem produksi yang presisi dan berkelanjutan.

Namun, pengembangan model deteksi penyakit tanaman yang andal masih menghadapi kendala signifikan, terutama keterbatasan ketersediaan dataset. Jumlah citra penyakit bawang merah yang tersedia relatif sedikit, sehingga model cenderung bias terhadap kelas dengan jumlah data lebih besar dan menghasilkan akurasi rendah pada kelas dengan representasi terbatas (Abbas et al., 2021). Dalam klasifikasi, ketidakseimbangan distribusi sampel antar kelas dapat memicu bias prediksi, di mana model lebih akurat pada kelas mayoritas dan mengabaikan kelas minoritas. Kondisi ini menurunkan efektivitas sistem deteksi secara keseluruhan (Xinmin et al., 2025), padahal akurasi pada kelas dengan jumlah data terbatas sering kali justru paling penting untuk mendukung keberhasilan klasifikasi penyakit tanaman, termasuk penyakit pada bawang merah.

Pendekatan augmentasi konvensional, seperti rotasi, flipping, zooming, maupun penyesuaian kontras, memang efektif dalam menambah jumlah data citra (Han et al., 2025). Namun, metode ini tidak mampu menghasilkan variasi semantik baru yang diperlukan untuk memperkaya distribusi data. Penelitian yang dilakukan oleh Prashant dan Bagade menunjukkan bahwa penerapan augmentasi konvensional pada citra bambu muda berhasil meningkatkan akurasi klasifikasi hingga 97,87% melalui kombinasi CNN dan Random Forest, tetapi keterbatasan pada aspek variasi semantik tetap terlihat (Prashant & Bagade, 2025). Temuan serupa juga dilaporkan oleh Siam et al. (2025) pada kasus penyakit kunyit, di mana augmentasi konvensional mampu meningkatkan akurasi model Inception-v3 menjadi 97,36%, meskipun hasil tersebut masih bergantung pada transformasi sederhana tanpa memperkaya kompleksitas visual citra (Siam et al., 2025).

Metode konvensional hanya melakukan transformasi geometris sederhana tanpa menambah kompleksitas visual yang dibutuhkan untuk memperkaya distribusi data (Alimisis et al., 2025). Keterbatasan ini membuat metode konvensional kurang efektif dalam merepresentasikan keragaman gejala penyakit tanaman yang bersifat kompleks dan tidak seimbang. Oleh sebab itu, diperlukan pendekatan generatif yang dapat menghasilkan citra sintesis dengan variasi visual yang lebih kaya dan representatif. Metode generatif dipandang sebagai alternatif yang lebih prospektif dibandingkan augmentasi tradisional, khususnya dalam bidang pertanian yang kerap menghadapi keterbatasan dataset serta ketidakseimbangan antar kelas.

Pendekatan berbasis *Generative Adversarial Networks* (GAN) mulai digunakan untuk mengatasi keterbatasan tersebut. Penelitian yang dilakukan oleh Abbas et al. membuktikan bahwa penambahan citra sintetis hasil GAN pada dataset tomat meningkatkan akurasi klasifikasi hingga 99,51%, jauh lebih tinggi dibandingkan tanpa augmentasi (Abbas et al., 2021). Meskipun demikian, sejumlah penelitian terbaru menekankan bahwa GAN memiliki kelemahan, seperti kerentanan terhadap *mode collapse* dan kualitas sampel yang tidak konsisten, sehingga diperlukan metode generatif yang lebih stabil. Selain itu, efektivitas augmentasi generatif tidak hanya ditentukan oleh jumlah citra sintetis yang dihasilkan, tetapi juga oleh kemampuan model dalam merepresentasikan variasi semantik yang kompleks (Ding et al., 2025).

Diffusion Model muncul sebagai salah satu pendekatan *generative* yang digunakan untuk mengatasi keterbatasan augmentasi tersebut. *Diffusion Model* bekerja dengan prinsip menambahkan noise secara bertahap pada data pelatihan dan kemudian belajar membalikkan proses tersebut untuk merekonstruksi data (Alimisis et al., 2025). Proses ini memungkinkan *diffusion model* menghasilkan citra yang lebih stabil, realistis, dan bervariasi (Mirowski & Fabijańska, 2026). Penelitian Kim et al. menunjukkan bahwa penerapan *Denoising Diffusion Probabilistic Models* (DDPM) mampu mengatasi permasalahan *occlusion* pada buah melon oriental dan secara signifikan meningkatkan akurasi estimasi ukuran buah. (Kim et al., 2025). Yoon & Lee juga membuktikan bahwa augmentasi berbasis DDPM dapat meningkatkan akurasi klasifikasi kesehatan tanaman *green wall* hingga 4% dibandingkan baseline (Yoon & Lee, 2025). Meskipun *diffusion models* telah terbukti unggul dalam menghasilkan citra berkualitas tinggi dan menawarkan solusi menarik terhadap keterbatasan data pelatihan, kelemahan utamanya terletak pada kompleksitas komputasi yang tinggi dan kebutuhan memori yang besar (Kebaili et al., 2025). Model ini umumnya berjalan langsung pada ruang piksel berdimensi tinggi, sehingga proses pelatihan membutuhkan sumber daya GPU yang sangat besar, waktu optimisasi yang panjang, serta inferensi yang mahal akibat evaluasi berurutan dalam banyak langkah sampling (Rombach et al., 2022).

Untuk mengatasi keterbatasan tersebut, *Latent Diffusion Model* (LDM) diperkenalkan dengan memanfaatkan autoencoder untuk memproyeksikan citra dari ruang piksel berdimensi tinggi ke ruang laten (Lu et al., 2026). Proses difusi yang dilakukan pada ruang laten berdimensi rendah membuat model ini secara efektif menurunkan konsumsi memori dan biaya komputasi yang terkait dengan *diffusion model* (Kebaili et al., 2025). Setelah proses generasi selesai, representasi laten didekodekan kembali ke ruang piksel untuk menghasilkan citra sintetis dengan kualitas tinggi yang tetap mempertahankan informasi semantik penting (Rombach et al., 2022). Penelitian yang dilakukan oleh Moreno et al. menggunakan Latent Denoising Diffusion Probabilistic Models untuk klasifikasi gulma, dan hasilnya melampaui metode generatif konvensional seperti GAN dengan akurasi mencapai 98,52% (Moreno et al., 2023). Bahkan Morís & Moura mengintegrasikan *semantic-guided latent diffusion* untuk diagnosis neovaskularisasi pada citra OCT-A, yang meningkatkan akurasi deteksi hingga 96,50% (Morís & Moura, 2025).

Meskipun *Latent Diffusion Model* (LDM) telah berhasil menurunkan kompleksitas komputasi dengan memindahkan proses difusi dari ruang piksel ke ruang laten berdimensi rendah (Lu et al., 2026), pelatihan ulang model difusi berskala besar tetap

membutuhkan sumber daya yang signifikan ketika diadaptasikan ke domain baru karena memerlukan langkah sampling dan pelatihan ulang penuh ketika domain berubah (Dhariwal & Nichol, 2021). Untuk mengatasi keterbatasan ini, digunakan pendekatan *Low-Rank Adaptation* (LoRA), yaitu teknik fine-tuning yang hanya memperbarui proyeksi berperingkat rendah dari matriks bobot besar dalam model. Dengan cara ini, LoRA dapat mengurangi jumlah parameter yang perlu dilatih ulang, sehingga menghemat memori GPU, mempercepat proses pelatihan, dan memungkinkan adaptasi model pada dataset terbatas tanpa kehilangan performa generative (Hu et al., 2021).

Oleh karena itu, pemanfaatan *Latent Diffusion Model* (LDM) yang diintegrasikan dengan *Low-Rank Adaptation* (LoRA) menjadi relevan untuk menjawab tantangan keterbatasan data dan tingginya kebutuhan komputasi pada model difussion. LDM memungkinkan proses generasi citra dilakukan pada ruang laten berdimensi rendah sehingga lebih efisien, sementara LoRA memberikan fleksibilitas adaptasi ke domain khusus dengan biaya pelatihan yang jauh lebih ringan. Kombinasi keduanya diharapkan mampu menghasilkan augmentasi citra penyakit bawang merah yang lebih representatif sekaligus efisien secara komputasi dalam mendukung sistem deteksi penyakit tanaman agar lebih akurat dan aplikatif.

1.2 Landasan Teori

Untuk mendukung pembuatan karya ilmiah ini, maka perlu dikemukakan hal-hal atau teori-teori yang berkaitan dengan permasalahan dan ruang lingkup pembahasan sebagai landasan dalam pembuatan karya ilmiah. Adapun hal-hal atau teori-teori yang akan dibahas antara lain sebagai berikut.

1.2.1 Tanaman Bawang Merah

Bawang merah (*Allium ascalonicum* L) family Lilyceae yang berasal dari Asia Barat merupakan salah satu komoditas hortikultura yang mempunyai akar serabut dengan daun yang berbentuk silinder berongga dan umbi yang berlapis. Umbi bawang merah terbentuk dari pangkal daun yang bersatu dan berbentuk batang yang berubah bentuk menjadi membesar dan membentuk umbi lapis (Dahlianawati et al., 2020). Bawang merah merupakan salah satu bumbu dapur yang sering digunakan dalam masakan dan digunakan sebagai obat herbal dalam terapi pengobatan. Keunggulan tersebut menjadikan bawang merah sebagai barang berharga untuk penggunaan sehari-hari (Jumrayanti et al., 2023).

Potensi pengembangan bawang merah sangat besar seiring dengan kebutuhan produk hortikultura yang dikonsumsi masyarakat, baik lokal maupun internasional. Bawang merah adalah salah satu dari tiga spesies *Allium* yang sangat berharga dan bernilai ekonomi tinggi (Aprilia & Aini, 2022). Kabupaten Enrekang, Sulawesi Selatan, merupakan salah satu sentra utama produksi bawang merah di Indonesia. Pada tahun 2017 produksi mencapai 110.798,7 ton, kemudian menurun menjadi 73.581,1 ton pada tahun 2018. Selanjutnya, produksi kembali meningkat menjadi 80.017,3 ton di tahun 2019 dan 102.872,6 ton pada tahun 2020 (BPS Sulawesi Selatan, 2021). Fluktuasi produksi tersebut berdampak pada pendapatan petani, yang

banyak mengeluhkan penurunan hasil akibat serangan berbagai penyakit pada tanaman bawang merah.



Gambar 1. 1 Tanaman Bawang Merah

1.2.2 Penyakit Tanaman Bawang Merah

Perbanyakan bawang merah dapat dilakukan melalui dua cara, yaitu secara vegetatif menggunakan umbi dan secara generatif menggunakan benih. Penggunaan umbi sebagai bahan tanam secara berulang berpotensi menurunkan mutu umbi maupun hasil produksi, serta meningkatkan kerentanan terhadap penyakit yang terbawa bersama umbi. Infeksi patogen tanaman, baik yang disebabkan oleh jamur, bakteri, maupun virus, menjadi salah satu hambatan utama dalam budidaya bawang merah dan dapat menyebabkan penurunan produktivitas. Infeksi patogen tanaman yang disebabkan oleh jamur, bakteri, maupun virus merupakan salah satu hambatan utama dalam budidaya bawang merah karena dapat menurunkan produktivitas (Budiarti et al., 2022). Berikut merupakan beberapa penyakit yang sering menyerang tanaman bawang merah

a. Bercak Ungu (*Purple Blotch*)

Penyakit bercak ungu yang disebabkan oleh jamur *Alternaria porri* merupakan salah satu kendala utama dalam budidaya bawang merah karena dapat menimbulkan kerusakan serius dan menurunkan hasil panen secara signifikan. Gejala awal biasanya muncul dalam waktu 1–4 hari setelah infeksi, ditandai dengan pembusukan umbi yang kemudian berkembang menjadi bercak berwarna merah keunguan gelap dan akhirnya berubah menjadi coklat kehitaman. Perkembangan penyakit ini sangat dipengaruhi oleh berbagai faktor, antara lain musim, waktu tanam, tingkat kelembapan, suhu, fase pertumbuhan tanaman (Ahmad et al., 2020).



Gambar 1. 2 Penyakit Bercak Ungu

b. Moler (Fusarium)

Layu fusarium atau busuk umbi merupakan penyakit yang disebabkan oleh jamur *F.oxysporum*. Gejala visual penyakit moler memperlihatkan ciri yang khas yaitu warna daun menguning dan bentuknya cenderung melengkung terpelintir (terputar). Hal ini menyebabkan tanaman menjadi cepat layu, kurus kekuningan dan terkulai seperti akan roboh. Tanaman sangat mudah tercabut karena pertumbuhan akar terganggu bahkan membusuk. Pada serangan tingkat tinggi tanaman akan mengalami rebah bahkan kematian. Sasaran infeksi jamur Fusarium adalah bagian dasar umbi lapis, sehingga mengakibatkan pertumbuhan akar maupun umbi terganggu dan pada dasar umbi terlihat jamur yang berwarna keputihan. Apabila umbi lapis dipotong membujur terlihat adanya pembusukan yang berawal dari dasar umbi meluas ke atas maupun ke samping. Serangan lanjut akan mengakibatkan tanaman mati, yang dimulai dari ujung daun dan dengan cepat menjalar ke bagian bawah (Budiarti et al., 2022).



Gambar 1. 3 Penyakit Moler

c. Hawar Daun (Leaf Blight)

Penyakit hawar daun atau biasa disebut dengan antraknosa adalah penyakit tanaman bawang merah yang disebabkan oleh patogen jamur *C. gloeosporioides* (Penz.). Gejala khas yang nampak pada tanaman yaitu daun menguning, melengkung, berlekuk, klorosis dan malformasi pada leher daun. Jika infeksi pada daun berlanjut,

maka terbentuk koloni konidia kehitam-hitaman. Sehingga dapat menyebabkan akar tanaman menjadi lebih sedikit dan lebih pendek dibanding pada tanaman sehat, kemudian tanaman akan mati (Budiarti et al., 2022).



Gambar 1. 4 Penyakit Hawar Daun

d. Virus Bercak Kuning (Iris Yellow Spot Virus)

Iris Yellow Spot Virus (IYSV) merupakan penyakit virus patogen yang menyerang tanaman bawang dan menjadi salah satu ancaman serius dalam budidaya. Infeksi virus ini menyebabkan kerusakan parah dengan mengganggu area fotosintesis pada daun, sehingga kemampuan tanaman membentuk umbi berukuran optimal menjadi terbatas dan berdampak pada hasil serta kualitas bawang. Gejala khas yang ditimbulkan antara lain muncul bercak berbentuk belah ketupat berwarna kuning pucat hingga nekrotik pada daun, daun tampak mengering atau patah, serta pertumbuhan tanaman menjadi kerdil. Pada serangan berat, daun dapat mati sebelum waktunya sehingga tanaman tidak mampu berfotosintesis secara normal, yang akhirnya menurunkan produktivitas dan kualitas panen bawang merah secara signifikan (Kritzman et al., 2001).




Gambar 1. 5 Penyakit Bercak Kuning

1.2.3 Diffusion Model

Diffusion Models (DM) merupakan model generatif berbasis probabilitas yang bekerja dengan prinsip forward process dan reverse process. Pada tahap forward process, data asli secara bertahap diberi noise Gaussian hingga berubah menjadi distribusi acak. Sebaliknya, pada reverse process, model dilatih untuk menghapus noise tersebut langkah demi langkah hingga kembali membentuk data yang menyerupai distribusi asli (Croitoru et al., 2022). Mekanisme ini membuat DM mampu menghasilkan citra dengan kualitas tinggi dan distribusi yang lebih stabil dibandingkan GAN. Selain itu, DM memiliki keunggulan dalam hal stabilitas pelatihan karena tidak melibatkan dua jaringan (Generator dan Diskriminator) seperti pada GAN (Yang et al., 2023).

1.2.4 Latent Diffusion Model

Latent Diffusion Models (LDM) merupakan pengembangan dari Diffusion Model yang menggunakan variational autoencoder (VAE) untuk memproyeksikan citra dari ruang piksel berdimensi tinggi ke ruang laten berdimensi rendah. Proses difusi kemudian dilakukan di ruang laten ini, sehingga lebih efisien dalam penggunaan memori dan waktu pelatihan. Setelah proses selesai, representasi laten didekodekan kembali ke ruang piksel untuk menghasilkan citra sintetis. Peran autoencoder sangat penting, encoder memampatkan citra ke ruang laten, sementara decoder mengembalikannya ke ruang piksel. Arsitektur U-Net biasanya digunakan dalam proses denoising karena kemampuannya mempertahankan detail spasial melalui skip connections (Rombach et al., 2022).




Gambar 1. 6 Arsitektur Latent Diffusion Model

1.2.5 Low-Rank Adaptation

Low-Rank Adaptation (LoRA) merupakan teknik yang dikembangkan untuk mengatasi tantangan fine-tuning model besar yang membutuhkan sumber daya komputasi sangat tinggi. Definisinya, LoRA adalah metode yang menambahkan *low-rank decomposition* pada bobot besar dalam jaringan saraf, sehingga memungkinkan adaptasi model tanpa perlu memperbarui seluruh parameter. Dengan demikian, LoRA termasuk dalam kategori *parameter-efficient fine-tuning methods* (PEFT) (Hu et al., 2021). Pada penelitian ini, LoRA diterapkan pada lapisan *attention* yaitu Query, Key, dan Value yang terdapat pada arsitektur *denoising U-Net*. Pembatasan proses pelatihan hanya pada lapisan-lapisan ini untuk mengurangi jumlah parameter yang perlu

dioptimalkan. Sehingga, ukuran model menjadi lebih ringan karena hanya matriks ber-rank rendah A dan B yang disimpan, bukan keseluruhan parameter U-Net. Pendekatan ini tidak hanya mengurangi kebutuhan ruang penyimpanan, tetapi juga meningkatkan efisiensi proses pelatihan secara keseluruhan.



Gambar 1. 7 Arsitektur LoRA

1.2.6 Augumentasi Data

Augmentasi data citra adalah teknik untuk memperluas dan memperkaya dataset dengan menghasilkan variasi baru dari data asli. Metode konvensional meliputi rotasi, flipping, cropping, scaling, dan perubahan intensitas warna. Teknik ini sederhana dan efektif, tetapi hanya memodifikasi data yang sudah ada sehingga variasinya terbatas (Brennan, 2023).

Pendekatan modern menggunakan model generatif seperti GAN, VAE, dan Diffusion Models untuk menghasilkan citra sintetis yang benar-benar baru. Cara kerjanya adalah dengan melatih model pada dataset asli, lalu menggunakan model tersebut untuk menghasilkan citra baru yang tetap mempertahankan pola semantik penting. Dibandingkan GAN yang sering mengalami mode collapse dan VAE yang cenderung menghasilkan citra buram, Diffusion Models (khususnya LDM) menawarkan keseimbangan antara kualitas dan keragaman citra sintetis.

1.2.7 Metrik Evaluasi

Untuk memastikan efektivitas metode augmentasi dan klasifikasi yang digunakan dalam penelitian ini, diperlukan serangkaian metrik evaluasi yang mampu menilai baik kualitas citra hasil generasi maupun performa model klasifikasi. Evaluasi dilakukan secara komprehensif dengan membagi metrik menjadi dua kategori utama, yaitu evaluasi kualitas citra dan evaluasi kinerja model klasifikasi.

a. Evaluasi Kualitas Citra

Kualitas citra hasil augmentasi citra akan dievaluasi menggunakan dua metrik utama, yaitu *Fréchet Inception Distance (FID)* dan *Structural Similarity Index (SSIM)*. FID digunakan untuk mengukur kesamaan distribusi fitur antara citra sintetis yang dihasilkan oleh *Latent Diffusion Model* dengan citra asli, nilai FID yang lebih rendah menunjukkan bahwa citra hasil augmentasi semakin realistis dan mendekati distribusi data nyata. Sementara itu, SSIM berfungsi untuk menilai kesamaan struktural antara citra sintetis dan citra referensi dengan mempertimbangkan aspek luminance, kontras, serta struktur. Nilai SSIM yang mendekati 1 menandakan tingkat kemiripan visual yang tinggi.

b. Evaluasi Model Klasifikasi

Evaluasi model klasifikasi dilakukan dengan menggunakan *confusion matrix*, yang memberikan gambaran menyeluruh mengenai performa klasifikasi. Dari matriks ini dapat diturunkan sejumlah parameter kinerja, antara lain *Specificity*, *Recall*, *Accuracy*, *Precision*, *False Positive Rate (FPR)*, *False Negative Rate (FNR)*, serta *F1-score* (Pratap & Kumar, 2023). *Accuracy* menunjukkan persentase prediksi yang sesuai dengan label sebenarnya, sedangkan *Precision* mengukur tingkat keandalan prediksi positif. *Specificity* menilai proporsi kelas negatif yang berhasil diidentifikasi dengan benar, sementara *Recall* mengukur proporsi kelas positif yang terdeteksi secara akurat. Adapun *F1-score* digunakan sebagai metrik gabungan yang menyeimbangkan antara *Precision* dan *Recall*, sehingga memberikan indikator tunggal untuk menilai kinerja keseluruhan model.

1.3 Rumusan Masalah

Berdasarkan latar belakang masalah di atas, maka rumusan masalah pada penelitian ini adalah

- 1.3.1 Bagaimana mengoptimalkan latent diffusion model untuk menghasilkan augmentasi citra penyakit bawang merah yang representatif?
- 1.3.2 Bagaimana pengaruh integrasi Low-Rank Adaptation (LoRA) dalam Latent Diffusion Model terhadap performa klasifikasi multikelas penyakit tanaman bawang merah?

1.4 Batasan Masalah

Penetapan batasan masalah diperlukan agar penelitian lebih terarah, fokus, dan sesuai dengan tujuan yang ingin dicapai. Oleh karena itu, penelitian ini menetapkan batasan sebagai berikut:

- 1.4.1 Penelitian ini difokuskan pada klasifikasi multikelas penyakit bawang merah yang terdiri dari lima kelas, yaitu sehat, bercak ungu (*purple blotch*), Moler (*Fusarium*) hawar daun (*leaf blight*), dan virus bercak kuning (*iris yellow spot virus*)

- 1.4.2 Arsitektur dasar klasifikasi yang digunakan adalah *Convolutional Neural Network* (CNN) dengan dataset hasil augmentasi sebagai input
- 1.4.3 Evaluasi kualitas citra sintetis dilakukan menggunakan metrik *Fréchet Inception Distance (FID)* dan *Structural Similarity Index (SSIM)*
- 1.4.4 Evaluasi performa klasifikasi multikelas dilakukan menggunakan metrik *Accuracy*, *Precision*, *Recall*, dan *F1-score* untuk setiap kelas

1.5 Tujuan Penelitian

Sejalan dengan latar belakang dan rumusan masalah yang telah dipaparkan, tujuan penelitian ini adalah

- 1.5.1 Melakukan optimalisasi *Latent Diffusion Model (LDM)* untuk menghasilkan augmentasi citra penyakit bawang merah yang lebih representatif melalui integrasi *Low-Rank Adaptation (LoRA)*.
- 1.5.2 Mengevaluasi efektivitas integrasi *LoRA* dalam *Latent Diffusion Model* untuk menghasilkan augmentasi citra penyakit bawang merah, baik dari segi kualitas citra sintetis maupun dampaknya terhadap peningkatan performa model klasifikasi multikelas penyakit tanaman

1.6 Manfaat Penelitian

Sejalan dengan tujuan dan ruang lingkup yang telah ditetapkan, penelitian ini diharapkan memberikan sejumlah manfaat yang dapat diuraikan sebagai berikut

- 1.6.1 Bagi peneliti, penelitian ini memberikan kontribusi metodologis dalam pengembangan *Latent Diffusion Model (LDM)* dengan integrasi *Low-Rank Adaptation (LoRA)* untuk augmentasi citra. Melalui proses ini, peneliti memperoleh pemahaman mendalam mengenai strategi optimisasi model generatif yang efisien, sekaligus meningkatkan keterampilan dalam merancang eksperimen, mengelola proses pelatihan, serta melakukan evaluasi komprehensif terhadap kualitas citra sintetis dan performa klasifikasi multikelas penyakit tanaman.
- 1.6.2 Bagi pemerintah dan industri pertanian, Penelitian ini berpotensi memberikan kontribusi nyata dalam pengembangan teknologi deteksi dini dan pengelolaan penyakit bawang merah. Dengan adanya model klasifikasi yang diperkuat melalui augmentasi citra berbasis diffusion, sistem monitoring dapat diimplementasikan secara lebih akurat dan efisien. Hal ini diharapkan mampu meningkatkan produktivitas pertanian sekaligus mengurangi kerugian akibat serangan penyakit, terutama pada kondisi lapangan dengan distribusi data yang tidak seimbang.
- 1.6.3 Bagi institusi pendidikan dan mahasiswa magister, penelitian ini menyediakan landasan baru bagi studi-studi selanjutnya dalam bidang klasifikasi penyakit tanaman dengan pendekatan generatif berbasis diffusion. Mahasiswa magister dapat menjadikan penelitian ini sebagai referensi penting untuk memahami metodologi pengembangan model deep learning, evaluasi performa, serta penerapan teknologi AI dalam konteks pertanian. Selain itu, hasil penelitian ini

dapat menginspirasi penelitian lanjutan yang berfokus pada permasalahan keterbatasan dataset dan bias kelas, sekaligus memperkaya pengembangan ilmu pengetahuan di masa depan.


BAB II

METODE PENELITIAN

2.1 Jenis Penelitian

Penelitian ini merupakan jenis penelitian eksperimental yang bersifat aplikatif, sehingga permasalahan yang dikaji dapat dianalisis melalui studi pustaka yang mengacu pada berbagai sumber literatur, seperti buku, jurnal, prosiding, serta artikel ilmiah yang relevan.

2.2 Tahapan Penelitian



Gambar 2. 1 Tahapan Penelitian

Berdasarkan gambar di atas, tahapan-tahapan dalam penelitian ini adalah sebagai berikut.

a. Identifikasi Masalah

Pada tahap ini dilakukan identifikasi terhadap keterbatasan jumlah serta variasi citra penyakit bawang merah yang berpengaruh langsung terhadap akurasi model klasifikasi. Permasalahan tersebut menimbulkan kebutuhan akan metode augmentasi citra yang tidak hanya efisien secara komputasi, tetapi juga mampu menghasilkan citra sintetis yang representatif dan relevan dengan kondisi nyata di lapangan.

b. Studi literatur

Tahap studi literatur dilakukan dengan mengumpulkan informasi dan referensi dari jurnal atau penelitian terkait dengan Latent Diffusion Models (LDM), Low-Rank Adaptation (LoRA), dan teknik augmentasi citra pada domain pertanian.

c. Pengumpulan dan Pengolahan Data

Tahap ini dilakukan dengan mengumpulkan dataset citra penyakit bawang merah melalui dua sumber utama, yaitu dokumentasi langsung di lapangan dengan pengambilan foto tanaman bawang merah yang menunjukkan gejala penyakit, serta dari internet melalui sumber *open source*. Setelah data terkumpul, dilakukan proses

pre-processing untuk menyiapkan citra sebelum digunakan dalam pelatihan model. Tahapan *pre-processing* meliputi penyesuaian ukuran (*resize*), normalisasi intensitas piksel, dan *filtering* guna meningkatkan kualitas citra serta memastikan konsistensi data yang akan diproses lebih lanjut.

d. Perancangan Sistem

Pada tahap ini dilakukan perancangan arsitektur sistem augmentasi citra berbasis LDM yang dioptimalkan dengan penyisipan LoRA pada layer-layer strategis dalam jaringan U-Net. Perancangan mencakup penentuan konfigurasi pelatihan model, strategi pembagian dataset, serta alur evaluasi kualitas citra sintetis. Seluruh proses dirancang secara modular, dimulai dari tahap *preprocessing* data hingga evaluasi akhir terhadap performa klasifikasi penyakit bawang merah.

e. Implementasi Sistem

Pada tahap ini dilakukan implementasi sistem dengan membangun model augmentasi citra berbasis LDM yang dioptimalkan menggunakan LoRA. Model dilatih untuk menghasilkan citra sintetis penyakit bawang merah yang representatif. Selanjutnya, dilakukan integrasi antara dataset citra asli dan citra sintetis untuk membentuk dataset pelatihan yang digunakan dalam pengembangan model klasifikasi penyakit bawang merah.

f. Pengujian dan Analisis

Tahap ini dilakukan untuk menilai kinerja sistem yang telah dibangun. Pertama, kualitas citra hasil augmentasi dievaluasi menggunakan metrik *Fréchet Inception Distance* (FID) untuk menilai tingkat realism citra sintetis, *Structural Similarity Index* (SSIM) untuk mengukur kesamaan struktur, luminansi, dan kontras antara citra sintetis dengan citra referensi. Selanjutnya, model klasifikasi penyakit bawang merah dilatih dan diuji menggunakan dataset gabungan (citra asli dan sintetis). Evaluasi performa klasifikasi dilakukan dengan mengukur metrik akurasi, presisi, dan *recall* untuk mengetahui tingkat keandalan model dalam mendeteksi penyakit.

g. Validasi

Tahap ini dilakukan validasi hasil klasifikasi dengan pakar pertanian atau agronomis untuk menilai relevansi citra sintetis dan akurasi klasifikasi.


h. Hasil dan Laporan

Setelah semua proses telah selesai, proses pembuatan laporan akan dilakukan dalam bentuk tugas akhir (tesis) dengan kontribusi penelitian terhadap augmentasi data efisien dan klasifikasi penyakit tanaman.

2.3 Sumber Data

Penelitian ini menggunakan dataset citra penyakit bawang merah yang diperoleh melalui dua sumber utama. Pertama, dokumentasi langsung di lapangan dengan melakukan pengambilan foto tanaman bawang merah yang sehat dan yang menunjukkan gejala penyakit sebagai representasi kondisi nyata. Kedua, pengumpulan data tambahan dari internet melalui sumber *open source* yang relevan. Kombinasi kedua sumber ini bertujuan untuk memperkaya variasi dataset sehingga mendukung proses augmentasi dan klasifikasi secara lebih komprehensif.

2.4 Perancangan Sistem



Gambar 2. 2 Rancangan Sistem. (a) Image Processing (b) Model Klasifikasi

Gambar di atas menjelaskan tentang alur pembuatan model untuk deteksi penyakit bawang merah menggunakan pendekatan Latent Diffusion Model (LDM) yang dioptimalkan dengan Low-Rank Adaptation (LoRA). Bagian (a) merupakan alur untuk image processing dan Bagian (b) merupakan alur untuk proses klasifikasi. Berikut adalah penjelasan terkait rancangan sistem yang diusulkan.

a. Image Processing

Tahap augmentasi citra bertujuan untuk memperkaya variasi dataset penyakit bawang merah sehingga model klasifikasi dapat dilatih dengan data yang lebih beragam dan representatif. Proses ini dilakukan menggunakan *Latent Diffusion Model* (LDM) yang dioptimalkan dengan *Low-Rank Adaptation* (LoRA).

1. Resize

Pada tahap ini dilakukan penyesuaian ukuran citra penyakit bawang merah agar seragam. Karena citra yang diperoleh dari lapangan maupun sumber terbuka memiliki resolusi berbeda-beda, maka dilakukan *resize* ke ukuran standar, misalnya 256×256 piksel. Langkah ini memastikan konsistensi input ke model dan mengurangi beban komputasi selama pelatihan.

2. VAE Encoder

Proses selanjutnya masuk ke LDM, tahap pertama yaitu VAE Encoder. Setelah citra di-*resize*, citra dikompresi ke dalam bentuk representasi laten menggunakan *Variational Autoencoder* (VAE Encoder). Representasi laten ini menyimpan informasi penting citra dalam dimensi yang lebih rendah, sehingga lebih efisien untuk diproses oleh model difusi.

3. U-Net + LoRA

Tahap selanjutnya dimana representasi laten kemudian diproses oleh arsitektur U-Net yang telah disisipkan dengan *Low-Rank Adaptation* (LoRA). U-Net berfungsi sebagai denoiser dalam proses difusi, menghilangkan noise dari representasi laten secara bertahap. LoRA digunakan untuk mengoptimalkan pelatihan dengan efisiensi parameter, memungkinkan adaptasi model terhadap domain penyakit bawang merah tanpa perlu melatih seluruh parameter dari awal. Kombinasi ini menghasilkan citra sintetis yang lebih representatif dan sesuai dengan karakteristik penyakit yang ditargetkan.

4. VAE Decoder

Setelah proses denoising selesai, representasi laten dikembalikan ke bentuk citra melalui *VAE Decoder*. Decoder ini merekonstruksi citra sintetis dari ruang laten ke ruang piksel, menghasilkan citra penyakit bawang merah yang baru namun tetap relevan secara visual dan semantik. Citra hasil rekonstruksi ini menjadi bagian dari dataset augmentasi yang akan digunakan dalam pelatihan model klasifikasi.

5. Evaluasi Kualitas Citra

Citra sintetis yang dihasilkan kemudian dievaluasi untuk memastikan kualitasnya. Evaluasi dilakukan menggunakan dua metrik utama: *Fréchet Inception Distance* (FID) untuk menilai tingkat realism citra dibandingkan citra asli, dan *Structural Similarity Index* (SSIM) untuk mengukur kesamaan struktur,

luminansi, dan kontras. Kedua metrik ini memberikan gambaran komprehensif tentang seberapa baik citra sintetis merepresentasikan kondisi nyata di lapangan.

b. Model Klasifikasi

Tahap selanjutnya dalam rancangan sistem adalah pengembangan model klasifikasi yang berfungsi untuk mengidentifikasi serta membedakan daun bawang merah yang sehat dengan yang mengalami penyakit. Proses ini dirancang sebagai bagian inti dari sistem yang diusulkan, di mana dataset hasil gabungan citra asli dan citra sintetis digunakan untuk melatih model agar mampu mengenali pola visual secara akurat. Berikut uraian lebih lanjut mengenai rancangan sistem klasifikasi yang diterapkan.

1. Split Data

Setelah dataset gabungan (citra asli dan sintetis) terbentuk, dilakukan proses pembagian data menjadi tiga subset: data pelatihan (train), validasi (val), dan pengujian (test). Pembagian ini penting untuk memastikan bahwa model klasifikasi dapat dilatih secara optimal, divalidasi untuk menghindari overfitting, dan diuji secara objektif.

2. Training Model


Pada tahap ini, model klasifikasi dijalankan menggunakan data pelatihan yang telah disiapkan. Selama proses pelatihan, parameter-parameter model dioptimalkan secara bertahap dengan tujuan meningkatkan kemampuan sistem dalam mengenali pola visual yang membedakan daun bawang merah sehat dari yang berpenyakit. Penyesuaian ini dilakukan agar model dapat mencapai performa terbaik dalam mendeteksi karakteristik citra secara konsisten dan akurat.

3. Best Model

Model yang dianggap paling optimal ditentukan berdasarkan hasil evaluasi pada data validasi. Pemilihan ini dilakukan untuk memastikan bahwa model tidak hanya mencapai tingkat akurasi tinggi, tetapi juga memiliki kemampuan generalisasi yang baik sehingga dapat bekerja secara konsisten pada data baru.

4. Evaluasi

Tahap akhir adalah pengujian model menggunakan data uji. Evaluasi dilakukan dengan mengukur metrik akurasi, presisi, F1 Score, dan recall untuk mengetahui seberapa baik model dalam mengklasifikasikan daun bawang merah yang sehat dan berpenyakit. Hasil evaluasi ini menjadi indikator utama keberhasilan sistem klasifikasi yang dibangun.



Gambar 2. 3 Flowchart Proses Pelatihan LDM dengan LoRA

Flowchart ini menggambarkan secara rinci proses pelatihan model Latent Diffusion (LDM) dengan arsitektur U-Net yang dilengkapi mekanisme Self-Attention dan Low-Rank Adaptation (LoRA). Proses dimulai dengan pengambilan dataset citra bawang merah yang kemudian dikodekan ke dalam ruang laten menggunakan VAE Encoder. Representasi laten ini kemudian diberi noise sesuai dengan timestep untuk mensimulasikan proses forward diffusion. Hasilnya berupa latent noisy yang menjadi input bagi U-Net. Di dalam U-Net, data melewati tiga tahap utama: downsampling untuk ekstraksi fitur lokal, bottleneck sebagai pusat agregasi informasi, dan upsampling untuk rekonstruksi resolusi. Di bagian bottleneck, diterapkan self-attention yang memungkinkan setiap posisi fitur berinteraksi secara global, serta LoRA yang menyisipkan adaptor ringan ke dalam bobot Q/K/V agar proses pelatihan lebih efisien tanpa melatih seluruh parameter model.

Setelah proses denoising, U-Net menghasilkan prediksi noise $\hat{\epsilon}$ yang dibandingkan dengan noise asli (ϵ) menggunakan fungsi loss Mean Squared Error (MSE). Gradien dari loss ini digunakan untuk memperbarui bobot LoRA, sementara bobot utama U-Net tetap dibekukan. Proses ini berlangsung secara iteratif per batch, dan setelah seluruh batch dalam satu epoch selesai diproses, model digunakan untuk menghasilkan sampel citra melalui proses reverse diffusion. Sampel yang dihasilkan kemudian dievaluasi menggunakan dua metrik utama: Fréchet Inception Distance (FID) untuk menilai kesamaan distribusi fitur antara citra hasil dan citra referensi, serta Structural Similarity Index Measure (SSIM) untuk menilai kesamaan struktur dan kualitas visual. Flowchart ini secara keseluruhan merepresentasikan alur pelatihan dan evaluasi LDM yang efisien dan terstruktur, dengan fokus pada adaptasi ringan melalui LoRA untuk domain citra bawang merah.

DAFTAR PUSTAKA

- Abbas, A., Jain, S., Gour, M., & Vankudothu, S. (2021). Tomato plant disease detection using transfer learning with C-GAN synthetic images. *Computers and Electronics in Agriculture*, 187(June), 106279. <https://doi.org/10.1016/j.compag.2021.106279>
- Ahmad, D. A., Sharma, S., Mahajan, R., MUSHTAQ, M., SALATHIA, A., AHAMAD, S., & SHARMA, J. P. (2020). *Overview of purple blotch disease and understanding its management through chemical, biological and genetic approaches*. 19(12), 3013–3024. [https://doi.org/10.1016/S2095-3119\(20\)63285-3](https://doi.org/10.1016/S2095-3119(20)63285-3)
- Alimisis, P., Mademlis, I., Radoglou-grammatikis, P., & Sarigiannidis, P. (2025). *Advances in Diffusion Models for Image Data Augmentation : A Review of Methods , Models , Evaluation Metrics and Future Research*.
- Aprilia, A. D., & Aini, L. Q. (2022). Pengujian Konsorsium Bakteri Antagonis Untuk Mengendalikan Penyakit Layu Fusarium Pada Tanaman Bawang Merah (*Allium Ascalonicum* L.) Di Kecamatan Dampit, Kabupaten Malang. *Jurnal Hama Dan Penyakit Tumbuhan*, 10(1), 29–38. <https://doi.org/10.21776/ub.jurnalhpt.2022.010.1.4>
- Brennan, R. (2023). *Image Data Augmentation Approaches : A Comprehensive Survey and Future directions*. 6223.
- Budiarti, S. W., Cahyaningrum, H., & Setyo, A. (2022). *Inventarisasi Penyakit Bawang Merah (Allium ascalonicum L .) Varietas Lokananta Asal Biji (True Shallot Seed) Disease Inventory of Shallots (Allium ascalonicum L .) Variety of Lokananta from Seed (True Shallot Seed)*. 3(2), 143–153.
- Croitoru, F., Hondru, V., Ionescu, R. T., & Shah, M. (2022). *Diffusion Models in Vision : A Survey*. 14(8), 1–25.
- Dahlianawati, D., Sofyan, S., & Jakfar, F. (2020). Analisis Pendapatan Usahatani Bawang Merah (*Allium ascalonicum* L) Di Kecamatan Banda Baro Kabupaten Aceh Utara. *Jurnal Ilmiah Mahasiswa Pertanian*, 5(4), 31–44. <https://doi.org/10.17969/jimfp.v5i4.15867>
- Deng, L., & Qin, J. (2025). Engineering Applications of Artificial Intelligence DAMSLNet : Dual-Attention Multi-Scale Lightweight Network for Plant Disease Classification. *Engineering Applications of Artificial Intelligence*, 159(PB), 111590. <https://doi.org/10.1016/j.engappai.2025.111590>
- Dhariwal, P., & Nichol, A. (2021). *Diffusion Models Beat GANs on Image Synthesis. NeurIPS 2021*.
- Ding, H., Huang, N., Wu, Y., & Cui, X. (2025). *Improving imbalanced medical image classification through GAN-based data augmentation methods*. 166(September 2024).
- Han, G., Kwaku, D., Asiedu, P., & Ebo, K. (2025). Heliyon Plant disease detection with generative adversarial networks. *Heliyon*, 11(7), e43002. <https://doi.org/10.1016/j.heliyon.2025.e43002>
- Hu, E., Shen, Y., Wallis, P., Allen, Z., Hu, C., Li, Y., Wang, S., & Lu, W. (2021). *LORA: LOW-RANK ADAPTATION OF LARGE LANGUAGE MODELS*. 1–26.
- Jumrayanti, Purnawansyah, Herdianti, D., & Satra, R. (2023). *Klasifikasi Penyakit Bawang Merah Menggunakan Naive Bayes dan CNNdengan Fitur GLCM*. 12(1),

1231–1240.

- Kebaili, A., Lapuyade-lahorgue, J., Vera, P., & Ruan, S. (2025). Computerized Medical Imaging and Graphics Multi-modal MRI synthesis with conditional latent diffusion models for data augmentation in tumor segmentation. *Computerized Medical Imaging and Graphics*, 123(March), 102532. <https://doi.org/10.1016/j.compmedimag.2025.102532>
- Kim, S., Xin, X., Kim, S. Y., Kim, G., Baek, M. gyu, Won, D. Y., Baek, C. H., & Kim, G. (2025). De-occlusion models and diffusion-based data augmentation for size estimation of on-plant oriental melons. *Plant Phenomics*, 7(3), 100097. <https://doi.org/10.1016/j.plaphe.2025.100097>
- Kritzman, A., Lampel, M., Raccach, B., Gera, A., & Dagan, B. (2001). *Distribution and Transmission of Iris yellow spot virus*. 85(8), 838–842.
- Lee, S. J., Yun, C., Im, S. J., & Park, K. R. (2024). Engineering Applications of Artificial Intelligence CNCAN: Contrast and normal channel attention network for super-resolution image reconstruction of crops and weeds. *Engineering Applications of Artificial Intelligence*, 138(PB), 109487. <https://doi.org/10.1016/j.engappai.2024.109487>
- Lu, D., Chen, Z., Liu, C., Hu, Y., & Wu, Q. M. J. (2026). Neurocomputing Facial sketch synthesis with multi-level guided latent diffusion model. *Neurocomputing*, 659(July 2025), 131734. <https://doi.org/10.1016/j.neucom.2025.131734>
- Mirowski, P., & Fabijańska, A. (2026). Biomedical Signal Processing and Control Diffusion model-based synthesis of brain images for data augmentation. *Biomedical Signal Processing and Control*, 113(PB), 108940. <https://doi.org/10.1016/j.bspc.2025.108940>
- Moreno, H., Gómez, A., Altares-López, S., Ribeiro, A., & Andújar, D. (2023). Analysis of Stable Diffusion-derived fake weeds performance for training Convolutional Neural Networks. *Computers and Electronics in Agriculture*, 214(August). <https://doi.org/10.1016/j.compag.2023.108324>
- Morís, D. I., & Moura, J. De. (2025). Semantic-guided generative latent diffusion augmentation approaches for improving the neovascularization diagnosis in OCT-A imaging. *Pattern Recognition Letters*, 189(December 2024), 31–37. <https://doi.org/10.1016/j.patrec.2025.01.003>
- Prashant, P., & Bagade, A. M. (2025). Advances in Bamboo Science Nursery level bamboo plant species classification using Deep Learning. *Advances in Bamboo Science*, 12(December 2024), 100175. <https://doi.org/10.1016/j.bamboo.2025.100175>
- Pratap, V. K., & Kumar, N. S. (2023). Smart Agricultural Technology High-precision multiclass classification of chili leaf disease through customized EfficientNetB4 from chili leaf images. *Smart Agricultural Technology*, 5(July), 100295. <https://doi.org/10.1016/j.atech.2023.100295>
- Rombach, R., Blattmann, A., Lorenz, D., & Esser, P. (2022). *High-Resolution Image Synthesis with Latent Diffusion Models*. 10684–10695.
- Siam, A. K. M. F. K., Nirob, A. S., Bishshash, P., & Ghosh, A. (2025). A data-driven approach to turmeric disease detection: Dataset for plant condition classification. *Data in Brief*, 59, 111435. <https://doi.org/10.1016/j.dib.2025.111435>

- Xinmin, T., Annan, X., Lihang, S., Junxuan, L., Xinyue, G., & Sirui, T. (2025). Knowledge-Based Systems Density clustering hypersphere-based self-adaptively oversampling algorithm for imbalanced datasets. *Knowledge-Based Systems*, 329(PB), 114407. <https://doi.org/10.1016/j.knosys.2025.114407>
- Yang, L., Zhang, Z., Song, Y., Hong, S., Xu, R., Zhao, Y., Zhang, W., Cui, B., & Yang, M. (2023). *Diffusion Models: A Comprehensive Survey of Methods and Applications*. 1(1). <https://doi.org/10.1145/3626235>
- Yoon, M., & Lee, Y. (2025). Novel augmentation techniques using diffusion models for green wall plant health classification. *Computers in Biology and Medicine*, 189(January), 109899. <https://doi.org/10.1016/j.combiomed.2025.109899>

LAMPIRAN

Lampiran 1a. State Of The Art Penelitian

No	Judul Karya Ilmiah	Objek dan Permasalahan	Metode Penyelesaian	Kinerja
1.	Nursery level bamboo plant species classification using Deep Learning (Prashant & Bagade, 2025)	Objek: Bamboo Nursery Permasalahan: Bagaimana kinerja model deep learning dalam mengidentifikasi spesies bambu muda pada tingkat persemaian dengan keterbatasan ciri morfologi dan jumlah dataset yang terbatas?	Augumentasi Konvensional, Bicubic, Nearest Neighbor, CNN & Random Forest	Penelitian tersebut menggunakan 800 citra asli dari empat spesies bambu, yang kemudian diaugmentasi menjadi 4000 citra. Data dibagi dengan rasio 75:15:15 untuk data latih, validasi, dan uji. Hasil pengujian pada data uji menunjukkan bahwa model VGG19 dengan augmentasi mencapai akurasi tertinggi sebesar 96,37%, sedangkan metode Classifusion (CNN + Random Forest) memberikan kinerja terbaik dengan akurasi 97,87%, presisi 0,98, recall 0,96, F1-score 0,97.
2.	A data-driven approach to turmeric disease detection: Dataset for plant condition classification (Siam et al., 2025)	Objek: Penyakit tanaman kunyit Permasalahan: Bagaimana kinerja model deep learning dalam mengidentifikasi penyakit tanaman kunyit berdasarkan citra daun dan akar?	Augumentasi Konvensional, Inception-v3	Penelitian tersebut menggunakan 1073 citra asli tanaman kunyit yang kemudian diaugmentasi menjadi 4628 citra, sehingga total dataset berjumlah 5701 citra. Data dibagi dengan rasio 80:20 untuk data latih dan uji. Hasil pengujian pada data uji menunjukkan bahwa model Inception-v3 dengan augmentasi mencapai akurasi tertinggi sebesar 97,36%, dibandingkan dengan 95,71% tanpa augmentasi. Selain itu, metrik evaluasi lainnya juga menunjukkan performa tinggi, dengan presisi 0,97, recall 0,96, dan F1-score 0,96,

No	Judul Karya Ilmiah	Objek dan Permasalahan	Metode Penyelesaian	Kinerja
				yang menegaskan efektivitas augmentasi dalam meningkatkan kinerja model klasifikasi penyakit tanaman kunyit.
3.	Improving imbalanced medical image classification through GAN-based data augmentation methods (Ding et al., 2025)	Objek: BloodMNIST, OrganCMNIST, PathMNIST, dan PneumoniaMNIST Permasalahan: Bagaimana kinerja model deep learning dapat ditingkatkan dalam klasifikasi citra medis dengan mengatasi masalah ketidakseimbangan data intra-class yang menyebabkan mode collapse dan menurunkan kualitas sampel sintetis?	CBLOF (Cluster-Based Local Outlier Factor), GAN, & One-Class SVM (OCS)	Penelitian tersebut menunjukkan bahwa metode yang diusulkan mampu menghasilkan sampel sintetis dengan keragaman dan kualitas lebih tinggi dibandingkan metode augmentasi tradisional maupun GAN konvensional serta meningkatkan akurasi klasifikasi rata-rata sekitar +3% pada ketiga dataset medis (BloodMNIST, OrganCMNIST, PathMNIST).
4.	Tomato plant disease detection using transfer learning with C-GAN synthetic images (Abbas et al., 2021)	Objek: Penyakit Daun Tomat (PlantVillage) Permasalahan: Bagaimana kinerja model deep learning dalam mengidentifikasi penyakit tanaman tomat berdasarkan citra daun, dengan keterbatasan jumlah data asli yang dapat menyebabkan masalah overfitting dan rendahnya kemampuan generalisasi model?	C-GAN, DenseNet121	Penelitian tersebut menunjukkan bahwa pada dataset asli PlantVillage, model DenseNet121 yang dilatih tanpa augmentasi sintetis hanya mampu mencapai akurasi sebesar 98,16% untuk klasifikasi 5 kelas, 95,08% untuk 7 kelas, dan 94,34% untuk 10 kelas. Namun, setelah ditambahkan citra sintetis hasil generasi C-GAN, performa model meningkat secara signifikan, dengan akurasi mencapai 99,51% pada klasifikasi 5 kelas, 98,65% pada 7 kelas, dan 97,11% pada 10 kelas.

No	Judul Karya Ilmiah	Objek dan Permasalahan	Metode Penyelesaian	Kinerja
5.	De-occlusion models and diffusion-based data augmentation for size estimation of on-plant oriental melons (Kim et al., 2025)	Objek: Ukuran buah melon oriental Permasalahan: Bagaimana cara mengatasi keterbatasan data dan permasalahan occlusion daun pada buah melon oriental dalam sistem budidaya vertikal agar estimasi ukuran buah dapat dilakukan secara akurat dan efisien?	Denoising Diffusion Probabilistic Models (DDPM), Amodal Mask2Former, Occlusion-aware RCNN (ORCNN)	Penelitian tersebut menunjukkan bahwa Amodal Mask2Former mencapai kinerja terbaik dengan nilai AP sebesar 85,92%, disertai MAE 5,46 mm untuk tinggi dan 4,20 mm untuk diameter, serta MAPE masing-masing 4,86% dan 5,33%. Sementara itu, ORCNN juga memberikan performa tinggi dengan AP 85,35%.. Peningkatan performa model <i>de-occlusion</i> dibandingkan model konvensional terlihat konsisten pada rasio occlusion 0–70%. Namun demikian, terdapat keterbatasan dalam pembuatan dataset sintesis dengan tingkat occlusion di atas 70%.
6.	GADM: Data augmentation using Generative Adversarial Diffusion Model for pulse-based disease identification (Fan et al., 2025)	Objek: Sinyal nadi Permasalahan: Bagaimana model deep learning mengatasi keterbatasan data dan ketidakseimbangan kelas pada sinyal nadi medis untuk meningkatkan akurasi klasifikasi hipertensi secara efisien?	Generative Adversarial Diffusion Model (GADM)	Penelitian tersebut menunjukkan bahwa model menggunakan 50% data nyata, akurasi awal sebesar 85,54% dapat ditingkatkan menjadi 88,34% setelah ditambahkan 10 ribu data sintesis. Ketika seluruh data nyata digunakan, akurasi mencapai 88,28%, dan meningkat lebih jauh hingga 94,33% dengan penambahan data sintesis. Selain itu, <i>recall</i> juga mengalami peningkatan signifikan hingga 86,94% ketika jumlah data sintesis yang digunakan mencapai 20 ribu sampel.

No	Judul Karya Ilmiah	Objek dan Permasalahan	Metode Penyelesaian	Kinerja
7.	Novel augmentation techniques using diffusion models for greenwall plant health classification (Yoon & Lee, 2025)	Objek: Kesehatan tanaman pada sistem <i>green wall</i> Permasalahan: Bagaimana meningkatkan akurasi klasifikasi kesehatan tanaman pada <i>green wall</i> dengan mengatasi keterbatasan data pada kategori <i>Slightly Wilted</i> yang bersifat sementara, dan rawan ambiguitas pelabelan?	Denoising Diffusion Probabilistic Models (DDPM)	Penelitian tersebut menunjukkan bahwa metode augmentasi berbasis DDPM mampu meningkatkan akurasi klasifikasi dan skor F1 hingga sekitar 4% dibandingkan model baseline yang hanya menggunakan bobot pra-latih ImageNet. Selain itu, metode ini tidak hanya meningkatkan kemampuan model dalam membedakan kondisi <i>Normal</i> , <i>Slightly Wilted</i> , dan <i>Wilted</i> , tetapi juga memberikan penilaian yang lebih rinci terhadap tingkat keparahan kesehatan tanaman.
8.	Diffusion model-based synthesis of brain images for data augmentation (Mirowski & Fabijańska, 2026)	Objek: Segmentasi lesi otak (citra MRI) Permasalahan: Bagaimana mengatasi keterbatasan dataset untuk segmentasi lesi otak, sehingga dapat melatih model AI yang akurat?	Custom diffusion model, Control Net	Penelitian tersebut menunjukkan bahwa citra sintetis dari diffusion models mampu mendekati kualitas data nyata, dengan penurunan performa segmentasi yang sangat kecil (kurang dari 1,5%). Integrasi data sintetis ke dalam pelatihan secara signifikan meningkatkan akurasi segmentasi lesi otak berbasis U-Net, terutama ketika data nyata terbatas
9.	Weed image classification with generative AI using latent denoising diffusion probabilistic model	Objek: Gulma Permasalahan: Bagaimana mengatasi keterbatasan data dan ketidakseimbangan kelas dalam	Latent Denoising Diffusion Probabilistic Models (DDPMs), Wiener filtering	Evaluasi pada penelitian tersebut dilakukan pada empat dataset yaitu DeepWeeds, Soybean Weed, Cotton Tomato Weed, dan Corn Weed yang mewakili variasi latar belakang, pencahayaan, serta morfologi gulma-tanaman. Pada dataset

No	Judul Karya Ilmiah	Objek dan Permasalahan	Metode Penyelesaian	Kinerja
	and Wiener filtering approach (Moreno et al., 2023)	klasifikasi gulma, sehingga dapat meningkatkan akurasi dan generalisasi model pada kondisi lapangan nyata?"		DeepWeeds, akurasi klasifikasi mencapai 98,52%, melampaui metode generatif konvensional seperti GAN. Selain itu, metrik evaluasi lain seperti presisi, recall, dan F1-score juga konsisten lebih unggul di seluruh dataset.
10.	Semantic-guided generative latent diffusion augmentation approaches for improving the neovascularization diagnosis in OCT-Aimaging (Morís & Moura, 2025)	Objek : Optical Coherence Tomography Angiography (OCT-A) Permasalahan: Bagaimana mengatasi keterbatasan data dan variabilitas visual pada citra OCT-A sehingga dapat meningkatkan akurasi diagnosis neovaskularisasi?"	Semantic-Guided Latent Diffusion	Penelitian tersebut mampu meningkatkan akurasi deteksi neovaskularisasi secara signifikan. Pada subset 3×3, akurasi tertinggi mencapai 96,50% ± 1,37%, sementara pada subset 6×6 diperoleh akurasi 95,79% ± 1,44%

Lampiran 1b. Kerangka Pemikiran

